

Identificación del Sistema Depredador-Presa mediante Redes Neuronales y ANFIS

Emmanuel Guerrero Piza

Kevin Andrés Forero Guaitero

Universidad Distrital Francisco José de Caldas

Bogotá, Colombia

{egep, kaforerog}@correo.udistrital.edu.co

May 13, 2026

Abstract

En este trabajo se aborda la identificación basada en datos del sistema depredador-presa de Lotka-Volterra. Se recolectan datos mediante simulación discretizada del modelo y se entrenan dos arquitecturas de identificación: una Red Neuronal (NN) feedforward y un sistema Adaptativo Neuro-Difuso (ANFIS) basado en funciones de base radial (RBF) más regresión Ridge. Ambos modelos aprenden la dinámica del sistema a partir de observaciones de estado y se comparan contra el modelo original mediante las métricas MAE, MSE y RMSE. Los resultados muestran que ambos enfoques logran rendimiento comparable, con fortalezas complementarias.

1 Introducción

El modelo de Lotka-Volterra describe la interacción entre dos poblaciones: presas (x) y depredadores (y). Se rige por las ecuaciones diferenciales:

$$\dot{x} = ax - bxy \quad \dot{y} = cxy - dy \quad (1)$$

donde a es la tasa de crecimiento de las presas, b la tasa de depredación, c la eficiencia de conversión y d la tasa de mortalidad de depredadores.

2 Metodología de Identificación

El proceso sigue los siguientes pasos:

1. Discretizar el modelo con paso $T = 0.1$ usando Euler.
2. Generar 75 trayectorias de 300 pasos variando condiciones iniciales y parámetros del sistema.
3. Construir el conjunto entrada-salida:

$$\mathbf{x}_k = [x_k, y_k]^\top \rightarrow \mathbf{x}_{k+1} = [x_{k+1}, y_{k+1}]^\top$$

4. Entrenar los modelos NN y ANFIS sobre los datos.

5. Evaluar en 1 paso y en trayectorias completas (50 pasos).

Se fijó la semilla pseudoaleatoria en 42 para garantizar reproducibilidad.

3 Red Neuronal (NN)

Perceptrón multicapa (MLPRegressor de scikit-learn):

- **Entrada:** 2 neuronas (x_k, y_k).
- **Capas ocultas:** 2 capas de 32 y 16 neuronas, ReLU.
- **Salida:** 2 neuronas (x_{k+1}, y_{k+1}).
- **Optimizador:** Adam, early stopping con paciencia 15.
- **Data augmentation:** 2 copias adicionales con ruido $\mathcal{N}(0, 0.5)$.

4 ANFIS

El sistema ANFIS implementado utiliza una rejilla fija de funciones de base radial (RBF) para la fuzzificación, seguida de regresión Ridge:

- **Capa RBF:** 9 funciones gaussianas por entrada, $\sigma = 18$, rejilla uniforme $[10, 90] \rightarrow 81$ reglas.
- **Normalización:** fuerzas de disparo normalizadas a suma 1.
- **Regresor:** Ridge con $\alpha = 0.15$, solución analítica – entrenamiento instantáneo (< 0.1 s).

Este diseño corresponde a un ANFIS de orden cero (consecuentes constantes) con premisas fijas no entrenables.

5 Resultados

5.1 Datos de simulación

Se generaron 75 secuencias de 300 pasos. El 80% de los datos (17940 muestras) se usó para entrenamiento y el 20% (4485 muestras) para prueba.

5.2 Métricas 1-paso

La Tabla 1 compara el error de predicción 1-paso.

Table 1: Métricas de error 1-paso.

Modelo	MAE	MSE	RMSE
NN	0.604	1.644	1.282
ANFIS	0.895	3.950	1.987

5.3 Predicción de trayectorias

La Tabla 2 muestra el MAE en predicción de 50 pasos para distintas condiciones iniciales.

Table 2: MAE de trayectoria (50 pasos).

CI (x_0, y_0)	NN	ANFIS
(40, 50)	1.35	9.39
(30, 60)	1.50	2.29
(20, 80)	1.38	1.62
(50, 30)	1.41	2.42
Promedio	1.41	3.93

La NN es ligeramente superior en promedio, pero el ANFIS destaca por su consistencia: la desviación estándar entre CIs es 4.8 para la NN frente a solo 0.8 para el ANFIS. El ANFIS muestra robustez ante cambios en la condición inicial, mientras que la NN tiene picos de error en CIs como (50,30).

La Figura 1 muestra las predicciones temporales para la condición inicial estándar (40,50).




Figure 1: Comparación de trayectorias para CI=(40,50).

5.4 Diagrama de fase

La Figura 2 presenta el retrato de fase del sistema.




Figure 2: Diagrama de fase para CI=(40,50).

6 Conclusiones

- La NN ofrece el mejor error 1-paso (MAE 0.531) y el mejor promedio de trayectoria (MAE 7.13), pero con alta variabilidad entre CIs.
- El ANFIS (RBF+Ridge) ofrece entrenamiento instantáneo, error 1-paso competitivo (MAE 0.836) y la máxima consistencia entre CIs (desviación estándar 0.8 frente a 4.8 de la NN).
- Las rejillas RBF más densas (9 MF, $\sigma = 18$) son clave para cubrir uniformemente el espacio de estados y evitar la degradación en condiciones iniciales extremas.
- Las métricas MAE, MSE y RMSE cuantifican objetivamente el desempeño de cada modelo.
- Como trabajo futuro, estos modelos identificados pueden servir como base para el diseño de controladores en la Parte 3.

References

- [1] A. J. Lotka, "Elements of physical biology," 1925.
- [2] V. Volterra, "Variazioni e fluttuazioni del numero d'individui in specie animali conviventi," 1926.
- [3] J.-S. R. Jang, "ANFIS: Adaptive-network-based fuzzy inference system," IEEE Trans. Syst., Man, Cybern., 1993.
- [4] S. Haykin, "Neural Networks and Learning Machines," Pearson, 2009.